Bases de datos censales del Aglomerado Rafaela: 2001, 2010 y 2022

Beca de investigación en la Universidad Nacional de Rafaela (UNRaf), dentro del proyecto «Hogares rafaelinos entre la producción-reproducción: prácticas de provisión en la primera década del siglo XXI».

Rol: **Investigador becario, procesamiento de datos** Stack: **Python · pandas · REDATAM · Excel**

3	298 mil	36 M	845
censos nacionales procesados y fusionados	personas (aprox.) en las bases finales del aglomerado	filas en el archivo fuente más grande	columnas en la base hogar-integrantes

EL PROBLEMA

El equipo necesitaba comparar la composición de los hogares de Rafaela a lo largo de veinte años, pero los datos estaban repartidos en tres censos con estructuras, códigos y niveles de detalle distintos. El 2001 venía como microdatos de todo el país; el 2010 no traía el código de radio censal; el 2022 solo estaba disponible agregado por radio. Además, los límites geográficos no coincidían entre fuentes y varias etiquetas tenían caracteres corruptos.

CÓMO LO RESOLVÍ

01 Extracción

Microdatos desde REDATAM, RedatamX y el paquete censoargentino, con lectura por bloques para archivos de millones de filas.

02 Recorte geográfico

Filtrado jerárquico provincia → departamento → fracción → radio y construcción del código REDCODE de 9 dígitos.

03 Validación

Contraste de totales contra mapa.poblaciones.org: en 2010, 1 hogar de diferencia sobre 31.684.

04 Limpieza y codificación

Códigos reemplazados por etiquetas legibles y corrección de errores de codificación de caracteres.

05 Fusión

Agregación por radio y fusión vertical de los tres censos, con 34 columnas unificadas para comparar categorías.

06 Documentación

Diccionario de variables, manual de usuario y scripts para que el equipo use las bases por su cuenta.

MUESTRA DE CÓDIGO

Leer un archivo de 36 millones de filas sin agotar la memoria

```
ids_hogar = set(hogares["HOGAR_REF_ID"])
partes = []
for bloque in pd.read_csv(ruta_personas, sep=";", chunksize=500_000):
    partes.append(bloque[bloque["HOGAR_REF_ID"].isin(ids_hogar)])
personas = pd.concat(partes, ignore_index=True)
```

Construir el código geográfico de 9 dígitos sin perder los ceros a la izquierda

```
df["REDCODE"] = (
    df["IDPROV"].astype(str).str.zfill(2)  +   # 82   Santa Fe
    df["IDDPTO"].astype(str).str.zfill(3)  +   # 021  Castellanos
    df["IDFRAC"].astype(str).str.zfill(2)  +   # 04   fracción
    df["IDRADIO"].astype(str).str.zfill(2)     # 01   radio
)
```

DESAFÍOS Y SOLUCIONES

Desafío	Solución
El archivo de personas del censo 2001 no entraba en memoria.	Lectura por bloques de 500.000 filas, filtrando solo los hogares del aglomerado.
El censo 2010 no traía el código de radio censal.	Reconstrucción del REDCODE recorriendo la jerarquía vivienda → radio → fracción → departamento.
El 2022 solo existe agregado por radio; 2001 y 2010 son microdatos.	Agregación de 2001 y 2010 al mismo nivel y fusión vertical con una columna de año.
Categorías distintas entre censos (13 de condición de actividad en 2001, 3 en 2010 y 2022).	Columnas unificadas que agrupan las categorías equivalentes, documentadas para su revisión.
Etiquetas con caracteres corruptos en las bases exportadas.	Corrección a nivel de bytes y diccionario de reemplazos sobre 101.208 registros.

ENTREGABLES

- 4 bases de fusión vertical 2001–2010–2022
- Base hogar-integrantes 2001: una fila por hogar con los datos de cada miembro según parentesco
- Diccionario de variables verificado con un script
- Manual de usuario y guías de uso
- Scripts en Python reutilizables por el equipo
- Diario de campo con cada decisión metodológica

HABILIDADES DEMOSTRADAS

Python · pandas · REDATAM / RedatamX · Excel · Grandes volúmenes de datos · Limpieza de datos · Integración de fuentes · Validación de datos · Documentación técnica